Detekcia objektov: modely, prípady použitia, príklady

Detekcia objektov je technika počítačového videnia, ktorá deteguje relevantné objekty v rámci obrázka alebo videa. Algoritmy detekcie objektov využívajú komplexné strojové učenie a architektúry hlbokého učenia na analýzu obrazových údajov a rozpoznávanie a lokalizáciu objektov záujmu. Výstup týchto algoritmov obsahuje názov objektu a ohraničujúci rámček pre informácie o polohe.

Detekcia objektov má rôzne praktické aplikácie vrátane lekárskeho zobrazovania, bezpečnostných detekčných systémov a samoriadiacich áut. Tento článok sa bude zaoberať detekciou objektov, jej fungovaním a niektorými praktickými aplikáciami.

Detekcia objektov

Detekcia objektov je schopnosť počítača identifikovať a lokalizovať objekt v rámci obrázka. Predpoklad je taký, že podobne ako ľudia, aj stroje by mali poznať všetky entity v rámci svojho referenčného rámca. Tieto entity môžu zahŕňať ľudí, zvieratá, autá, stromy atď. Počítačové videnie však prešlo dlhú cestu a dnes existuje mnoho pokročilých algoritmov strojového učenia na rozpoznávanie a segmentáciu obrazov. Pred posunom vpred je dôležité rozlíšiť, čo detekcia objektov a čo o nie je – *klasifikácia obrazov,detekcia objektov v obraze*, *segmentácia*.

Klasifikácia obrázkov aj detekcia objektov sa používajú na rozpoznávanie entít v rámci obrázkov. Algoritmus klasifikácie obrázkov však spája jednu triedu z trénovacích údajov s celým snímkom obrázka alebo videa bez ohľadu na to, koľko informácií obsahuje. Napríklad model klasifikátora mačiek poskytne pozitívnu odpoveď iba vtedy, ak je prítomná mačka. Klasifikačný model navyše neposkytuje žiadne informácie o umiestnení detekovaného objektu.

Detekcia objektov posúva klasifikačný algoritmus o krok ďalej. Okrem klasifikácie viacerých objektov v obrázku vracia anotácie pre ohraničovacie rámčeky zodpovedajúce umiestneniu každej entity. Dodatočné výhody umožňujú použitie modelu CV v niekoľkých aplikáciách v reálnom svete.

Segmentácia obrazu je podobná detekcii objektov, pretože vykonávajú rovnakú funkciu. Oba algoritmy detegujú objekty na obrázkoch a vydávajú súradnice pre lokalizáciu objektu. Namiesto kreslenia celých polí okolo objektov však segmentačné algoritmy generujú presné masky, ktoré pokrývajú objekty na úrovni pixelov.



Object detection vs. Image classification vs. Image segmentation

Tradičné algoritmy počítačového videnia využívajú techniky spracovania obrazu na klasifikáciu a úlohy detekcie objektov. Väčšina moderných trénovaných modelov však využíva komplexnú architektúru a učenie pod dohľadom (supervised). Tie využívajú anotácie množiny údajov a hlboké učenie na dosiahnutie vysokého výkonu a efektívnosti.

Detekcia objektov hlbokého učenia funguje mnohými spôsobmi v závislosti od nasadených algoritmov a modelov (napr. YOLO, SSD, R-CNN atď.).Vo väčšine prípadov sú tieto modely integrované do iných systémov a sú len jednou časťou celkového procesu detekcie, označovania a anotácie objektov na obrázkoch alebo videách. A to zahŕňa sledovanie viacerých objektov pre projekty počítačového videnia.

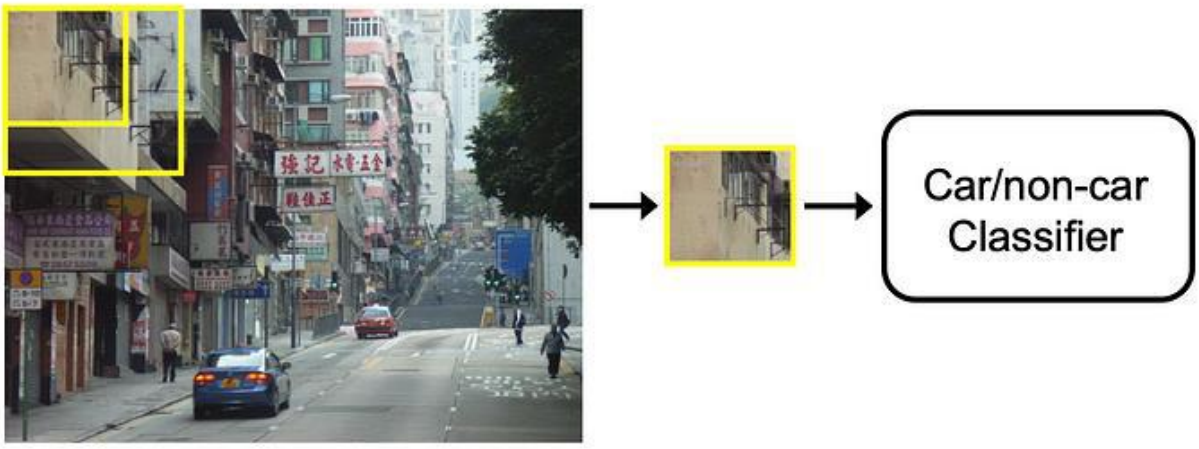
Detekcia objektov: Tradičné prístupy

Rôzne prístupy riešia detekciu odlišne. Možno ich rozdeliť do troch hlavných typov:

1. Nájdite zaujímových body, po ktorých nasleduje Houghovo hlasovanie
2. Posuvné okná
3. Návrhy regiónov (objektov) a klasifikácia každého regiónu

Sliding Window - Posuvné okno

Technika posuvného okna zahŕňa presunutie okna pevnej veľkosti cez obrázok. Tento proces sa opakuje na celom obrázku a výsledkom je sada ohraničujúcich políčok. Veľkosť okna a veľkosť kroku sú dôležité parametre, ktoré ovplyvňujú presnosť a efektivitu.



Základnou súčasťou úlohy je binárny klasifikátor. Časť obrazu, ktorá sa prekrýva s oknom, sa odoberie a vloží do klasifikátora automobilov, aby sa zistilo, či sa v ňom nachádza auto alebo nie. Následne sa vysunie okno a tento postup opakujeme, kým okno neprejde celou oblasťou na obrázku. Stručne povedané, opísaný proces je prístupom hrubej sily s mnohými lokálnymi rozhodnutiami.

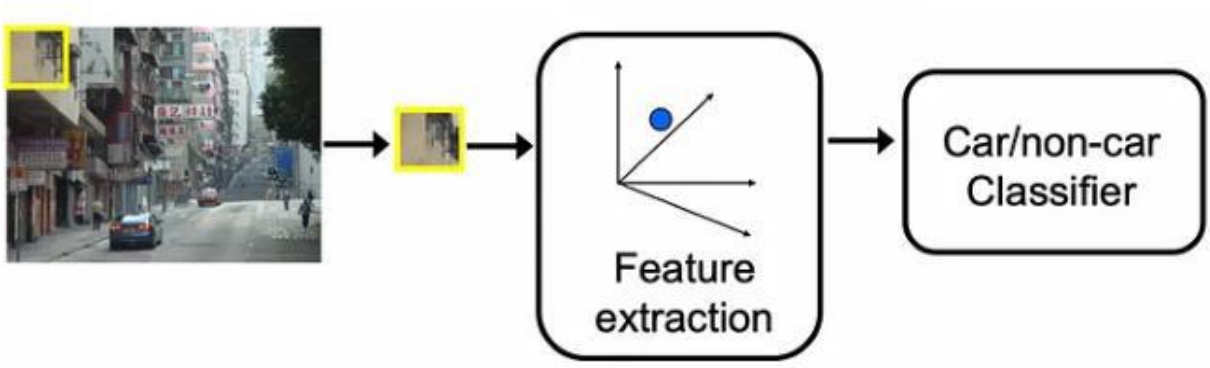
Tradičný prístup k detekcii objektov má zvyčajne tri fázy:

i) výber oblasti,
ii) extrakciu príznakova

iii) klasifikáciu objektu.

Ďalším bodom, ktorý je potrebné mať na pamäti, je, že okno nespracovaného obrázka nemožno vložiť do klasifikátora. Najprv musíme extrahovať vlastnosti z okna obrázka a klasifikátor sa rozhodne na základe daných vlastností. Preto je kompletný postup detekcie objektov metódou posuvného okna uvedený nižšie a kľúčovým komponentom je spôsob, akým extrahujeme funkcie.

1. V prvej fáze sa snažíme nájsť polohu objektu. Objekty majú rôznu veľkosť a pomer strán a môžu sa objaviť na rôznych miestach obrázka. Kvôli tomu musíme celý obrázok naskenovať pomocou viacškálového posuvného okna. Táto metóda je však výpočtovo nákladná a produkuje veľa irelevantných kandidátov.
2. V druhom kroku vykonáme fázu extrakcie príznakov napr. pomocou techník ako SIFT, HOG. Tieto príznaky poskytujú sémantickú a robustnú reprezentáciu. Avšak kvôli rôznym svetelným podmienkam, rozdielom v uhloch pohľadu a rôznemu pozadiu je veľmi ťažké manuálne navrhnúť robustný deskriptor vlastností, aby dokonale opísal všetky typy objektov.
3. V tretej klasifikačnej fáze vykonáme klasifikáciu cieľových objektov zo všetkých ostatných kategórií a na vytvorenie hierarchickejších, sémantickejších a informatívnejších reprezentácií pre vizuálne rozpoznávanie.



Problém s tradičným prístupom je v tom, že generovanie kandidátskych ohraničujúcich rámčekov pomocou techniky posuvných okien je výpočtovo nákladné a tiež ručne vytvorené funkcie nie vždy postačujú na dokonalý opis všetkých typov objektov.

Príklad: Chceme nájsť všetkých ľudí na tomto obrázku. Naše detekcie by prednostne nemali zahŕňať stromy, stĺpy lámp a dáždniky.



Detection Phase

- Scan image(s) at all scales and locations
- Extract features over windows
- Run linear SVM classifier on all locations
- Fuse multiple detections in 3-D position & scale space

Object detections with bounding boxes

Detection Phase

- Scan image(s) at all scales and locations
- Extract features over windows
- Run linear SVM classifier on all locations
- Fuse multiple detections in 3-D position & scale space

Object detections with

Detection window



- Shrink (down-scale) the image and slide again

Detection Phase

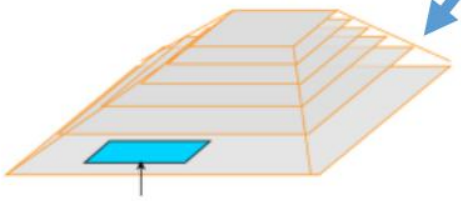
- Scan image(s) at all scales and locations
- Extract features over windows
- Run linear SVM classifier on all locations
- Fuse multiple detections in 3-D position & scale space

Object detections with bounding boxes



Scale-down the image, and slide the window again (the size of the window is always the same)

Scale-space pyramid



Detection window

- Done!

Detection Phase

- Scan image(s) at all scales and locations
- Extract features over windows
- Run linear SVM classifier on all locations
- Fuse multiple detections in 3-D position & scale space
- Object detections with bounding boxes

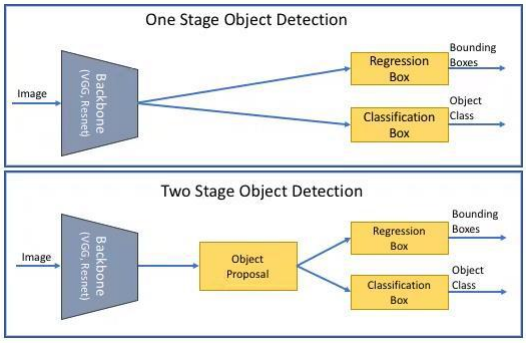


Voila!

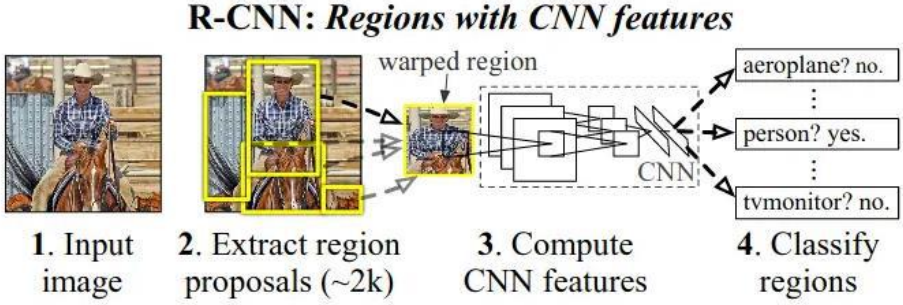
(Any idea how you would get rid of that tree detection or the upper right?)

Detekcia objektov: AI prístupy

Existujú dva hlavné prístupy k implementácii detekcie objektov: jednostupňové detektory objektov a dvojstupňové detektory objektov (One-stage vs. Two-stage). Oba prístupy zisťujú počet objektov v snímke alebo videu a klasifikujú tieto objekty alebo inštancie objektov pri odhadovaní veľkosti a polohy pomocou ohraničujúcich rámčekov (bounding boxes).



- **Jednostupňový** detektor nezahŕňa žiadne medzispracovanie. Zoberie vstupný obrázok a priamo vypíše triedu a ohraničujúce rámčeky. Medzi obľúbené jednostupňové detektory patria YOLO (vrátane v8), RetinaNet a SSD. Jednostupňové detektory získali popularitu vďaka svojej jednoduchosti a rýchlosti, čo ich robí vhodnými pre aplikácie, ako sú autonómne vozidlá, videokamery, a sledovanie objektov v reálnom čase. Tu sú niektoré kľúčové vlastnosti a charakteristiky jednostupňových detektorov:
    - **Efektívnosť**: Jednostupňové detektory sú navrhnuté pre spracovanie v reálnom čase alebo takmer v reálnom čase, čo ich robí vhodnými pre aplikácie, kde rýchlosť je kľúčová. Spracovávajú celý obraz v jednom predchodcovi.
    - **Jeden Prechod**: Tieto detektory vykonávajú detekciu objektov a klasifikáciu v jednom prechode cez neurónovú sieť. Priamo predikujú ohraničujúce rámce a triedy objektov na základe tejto jednej operácie.
- **Dvojstupňový** detektor naopak vykonáva dve samostatné úlohy. Prvý krok zahŕňa sieť zameranú na návrh regiónov, ktorá nám poskytne oblasť záujmu (region of interest, ROI), kde sa môže nachádzať objekt. Druhá sieť potom použije túto oblasť záujmu na vytvorenie ohraničujúcich rámčekov. Medzi obľúbené dvojstupňové detektory patria R-CNN, Faster R-CNN, Mask R-CNN a najnovší model G-RCNN.



-

Cvičenie

Detekcia objektov pomocou detektora YOLO

Použite Python a dostupný predtrénovaný model YOLO. Cieľom je spustiť detekciu objektov, zobraziť jej výsledky a porovnať ich pri rôznych nastaveniach.

Dokumentácia pre Python

https://docs.ultralytics.com/tasks/detect/

1. Načítajte predtrénovaný model YOLO a zistite, aké triedy objektov dokáže rozpoznávať.

2. Vyberte najmenej tri rôzne obrázky a vykonajte na nich detekciu objektov. Použite obrázky s objektmi patriacimi medzi triedy podporované modelom.

3. Vizualizujte výsledky detekcie. Pri nájdených objektoch zobrazte ohraničujúce rámčeky, názvy tried a skóre istoty.

4. Zmeňte prah istoty a porovnajte výsledky pri najmenej dvoch hodnotách. Sledujte, ako sa zmení počet a charakter zobrazených detekcií.

5. Nájdite príklad vynechaného alebo nesprávne rozpoznaného objektu. Stručne opíšte možné príčiny; podľa potreby vyskúšajte ďalší obrázok.

6. Uložte vybrané obrázky s výsledkami detekcie a svoje pozorovania zhrňte niekoľkými vetami.